实验四 机器翻译

下载和预处理数据集

1. 下载数据集;

```
Go. Va!
Hi. Salut!
Run! Cours!
Run! Courez!
Who? Qui?
Wow! Ca alors!
```

2. 数据预处理;

```
# 预处理数据集
#@save

def preprocess_nmt(text):
    def no_space(char, prev_char):
        return char in set(',.!?') and prev_char != ' '

# 使用空格替换不间断空格
# 使用小写字母替换大写字母

text = text.replace('\u202f', ' ').replace('\xa0', ' ').lower()
# 在单词和标点符号之间插入空格

out = [' ' + char if i > 0 and no_space(char, text[i - 1]) else char
        for i, char in enumerate(text)]

return ''.join(out)
```

```
text=preprocess_nmt(raw_text)
print(text[:80])
```

```
go . va !
hi . salut !
run ! cours !
run ! courez !
who ? qui ?
wow ! ça alors !
```

词元化


1. 将数据集中的每一行分割为源语言和目的语言;

```
# 词元化
#@save

def tokenize_nmt(text, num_examples=None):
    source, target=[],[]
    for i, line in enumerate(text.split('\n')):
        if num_examples and i>num_examples:
            break
        parts=line.split('\t')
        if len(parts)==2:
            source.append(parts[0].split(' '))
        target.append(parts[1].split(' '))
    return source, target

source, target=tokenize_nmt(text)
    source[:6], target[:6]
```

2. 绘制词元长度对直方图



构建词表

Vocab函数用于构建和管理词汇表,可以帮助我们将文本数据中的词汇映射到数字索引。

```
# <mark>查看词汇表中的词汇及对应的索引</mark>
print(src_vocab.token_to_idx)
```

```
{'<unk>': 0, '<pad>': 1, '<bos>': 2, '<eos>': 3, '.': 4, 'i': 5,
'you': 6, 'to': 7, 'the': 8, '?': 9, 'a': 10, 'is': 11, 'tom': 1
2, 'that': 13, 'he': 14, 'do': 15, 'of': 16, 'it': 17, 'this': 1
8, 'in': 19, 'me': 20, 'have': 21, "don't": 22, ',': 23, 'was':
24, 'my': 25, 'are': 26, 'for': 27, 'your': 28, 'what': 29,
"i'm": 30, 'we': 31, 'be': 32, 'want': 33, 'she': 34, 'not': 35,
'know': 36, 'like': 37, 'on': 38, 'with': 39, 'can': 40, 'his':
41, 'all': 42, 'did': 43, 'at': 44, "you're": 45, 'how': 46, 'g
o': 47, 'they': 48, 'him': 49, 'think': 50, 'and': 51, "it's": 5
2, 'about': 53, 'time': 54, "can't": 55, 'here': 56, 'very': 57,
"didn't": 58, 'get': 59, 'there': 60, 'her': 61, 'were': 62, 'a
s': 63, 'will': 64, 'had': 65, 'if': 66, 'why': 67, 'just': 68,
'up': 69, 'out': 70, 'no': 71, 'has': 72, 'one': 73, 'going': 7
4, 'would': 75, 'so': 76, 'good': 77, 'need': 78, 'tell': 79, 'a
n': 80, 'see': 81, "i'll": 82, 'come': 83, 'when': 84, 'from': 8
5, 'by': 86, 'really': 87, 'mary': 88, 'help': 89, 'who': 90, 'p
lease': 91, 'us': 92, "that's": 93, 'should': 94, 'could': 95,
'been': 96, "i've": 97, 'never': 98, 'more': 99, 'now': 100, 'wh
ere': 101, 'take': 102, 'something': 103, 'got': 104, 'too': 10
```

加载数据集

语言模型的序列样本必须有一个固定的长度,我们使用截断和填充的方式实现处理一个小批量的文本序列。

```
# 截断或填充文本序列
#@save

def truncate_pad(line, num_steps, padding_token):
    if len(line)>num_steps:
        return line[:num_steps] # 截断
    return line+[padding_token]*(num_steps-len(line)) # 填充

truncate_pad(src_vocab[source[0]], 10, src_vocab['<pad>'])
```

Out[49]: [47, 4, 1, 1, 1, 1, 1, 1, 1]

将文本序列转换成小批量数据集进行训练。

```
# 将机器翻译的文本序列转换成小批量
#@save

def build_array_nmt(lines, vocab, num_steps):
    lines = [vocab[1] for l in lines]
    lines = [1 + [vocab['<eos>']] for l in lines]
    array = torch.tensor([truncate_pad(
        l, num_steps, vocab['<pad>']) for l in lines])
    valid_len = (array != vocab['<pad>']).type(torch.int32).sum(1)
    return array, valid_len
```

训练模型

读取数据集的第一个小批量数据。

```
train_iter, src_vocab, tgt_vocab = load_data_nmt(batch_size=2, num_steps=8)
for X, X_valid_len, Y, Y_valid_len in train_iter:
    print('X:', X.type(torch.int32))
    print('X的有效长度:', X_valid_len)
    print('Y:', Y.type(torch.int32))
    print('Y的有效长度:', Y_valid_len)
    break
```

```
X: tensor([[ 9, 173, 118, 4, 3, 1, 1, 1],
        [ 39, 0, 5, 3, 1, 1, 1]], dtype=torch.int32)
X的有效长度: tensor([5, 4])
Y: tensor([[ 45, 46, 151, 5, 3, 1, 1, 1],
        [ 47, 12, 106, 5, 3, 1, 1, 1]], dtype=torch.int32)
Y的有效长度: tensor([5, 5])
```